

تشخیص چهره با استفاده از Laplacianfaces

سعید نوشادیان

چکیده - هدف ما در این مقاله ارائه روشی برای شناخت صورت به نام Laplacianface به وسیله ی حفظ پروجکشن های محلی (LPP) است. این روش تصویر صورت را به زیر فضای صورت نگاشت می دهد که متفاوت است از روش های تحلیلی اجزای اصلی (PCA) و تحلیل جدا کننده خطی (LDA) که تنها با ساختار اقلیدوسی فضای صورت کار می کردند. LPP می تواند اطلاعات محلی حفظ شده را پیدا و جایگذاری کرده و همچنین زیر فضائی از صورت پیدا کند که بهترین ساختار چند وجهی را تشخیص دهد. Laplacianface تخمین خطی بهینه برای توابع ویژه عملگر لاپلاس به روی صورت است. در این راه تغییرات ناخواسته ناشی از تغییر در نور، حالت صورت و ژست ممکن است حذف یا کاهش یابد. آنالیزهای تئوری نشان می دهد که PCA و LDA و LPP گراف های متعددی میتوانند به دست دهند در این مقاله روش های Eigenface، Fisherface، Laplacianface را در سه دسته داده مختلف با هم مقایسه می کنیم. نتایج تجربی نشان می دهد که روش Laplacianface دست آوردهای بهتری و همچنین میزان خطای کمتری در تشخیص صورت دارد.

کلید واژه- تشخیص چهره، بردار ویژه، ویژگی های محلی، LPP

۱- مقدمه

تصاویر Eigenfaces گفته می شود. LDA روش دیگری از کاهش ابعاد است که تلاش می کند اطلاعات پس از کاهش ابعاد بیشترین پراکندگی برون کلاسی را همزمان با کمترین پراکندگی درون کلاسی نسبت به یکدیگر داشته باشند. در واقع LDA تلاش می کند تا اطلاعات درون یک گروه را به یکدیگر نزدیک و اطلاعات با گروه بندی متفاوت را از یکدیگر دور نماید. LDA این عمل را در فضای جدایی پذیر خطی انجام می دهد که الزامات محوره های آن متعامد نمی باشند. به روش مبتنی بر LDA در شناسایی تصاویر Fisherfaces گفته می شود.

تکنیک های تشخیص چهره زیادی در چند دهه اخیر مورد استفاده قرار گرفته است که از موفق ترین آنها که بسیار مورد بررسی هم قرار گرفته اند تکنیک های مبتنی بر ظاهر^۱ هستند. طبق این روش ها، در صورتی که هر تصویر را با $n \times m$ پیکسل^۲ تعریف کنیم برای انجام عملیات باید محاسبات سنگینی در فضای $n \times m$ بعدی^۳ انجام گیرد که این ابعاد زیاد امکان پردازش صورت سریع و مقاوم^۴ را صلب می کند. یکی از راه حل های این مشکل، استفاده از روش های کاهش ابعاد^۵ است که معروف ترین و پرکاربردترین آنها تحلیل مولفه اساسی^۶ (PCA) و تحلیل تفکیک کننده خطی^۷ (LDA) می باشند.

تحلیل روش های PCA و LDA و PCA یک روش مبتنی بر بردار ویژه است برای مدل سازی تغییرات خطی در اطلاعات ابعاد بالا طراحی شده است. در این روش کاهش ابعاد از n به k ($k < n$) با استفاده از مقادیر اصلی بردار ویژه ماتریس (بیشترین پراکندگی را داشته باشد) به روش مبتنی بر PCA در پردازش و تشخیص

$$\max_{\mathbf{w}} \sum_{i=1}^n (y_i - \bar{y})^2, \quad (1)$$

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i. \quad (2)$$

$$\max_{\mathbf{w}} \frac{\mathbf{w}^T S_B \mathbf{w}}{\mathbf{w}^T S_W \mathbf{w}}, \quad (3)$$

$$S_B = \sum_{i=1}^l n_i (\mathbf{m}^{(i)} - \mathbf{m})(\mathbf{m}^{(i)} - \mathbf{m})^T, \quad (4)$$

$$S_W = \sum_{i=1}^l \left(\sum_{j=1}^{n_i} (\mathbf{x}_j^{(i)} - \mathbf{m}^{(i)})(\mathbf{x}_j^{(i)} - \mathbf{m}^{(i)})^T \right), \quad (5)$$

^۴ robust

^۵ Dimensionality reduction technique

^۶ Principle Component Analysis (PCA)

^۷ Linear (Fisher) Discriminant Analysis (LDA)

^۱ Appearance-based

^۲ Pixel

^۳ $n \times m$ dimensional

PCA و LDA داشته باشد. در این روش فاصله نقاطی که در همسایگی یکدیگر قرار دارند پس از تبدیل باید همچنان کم بوده و این‌ها همچنان در یک همسایگی قرار گیرند. از این‌رو تابع هدف که باید تعریف شود به آسانی به شکل زیر می‌باشد:

$$\min \sum_{ij} (y_i - y_j)^2 S_{ij}, \quad (6) \quad \text{تحلیلی}$$

S_{ij} در واقع همانند یک تابع کرنل^{۱۲} عمل کرده و با استفاده از آن می‌توان نقاطی که در همسایگی خاصی از هر نقطه قرار دارند را مشخص کرد. y_i همان نقاط حاصل از تبدیل می‌باشند که باید با نقاطی که در ابعاد بالا در یک همسایگی قرار دارند فاصله اندکی داشته باشند. از این حل این مسئله را می‌توان به صورت زیر بازنویسی کرد.

حال مسئله اصلی به مسئله یافتن بردارهای ویژه ماتریس LXL^T تبدیل شده است. اما برای این کار مشکلی وجود دارد. از آنجایی که در بسیاری از کاربردهای پردازش تصاویر صورت، تعداد تصاویر (n) بسیار کمتر از ابعاد آن ($m \times m$) می‌باشد، می‌توان انتظار داشت ماتریس LXL^T ماتریسی منفرد شده و وارون‌پذیر نباشد. برای حل این مسئله می‌توان قبل از انجام LPP اطلاعات را با

$$S_{ij} = \begin{cases} \exp(-\|\mathbf{x}_i - \mathbf{x}_j\|^2/t), & \|\mathbf{x}_i - \mathbf{x}_j\|^2 < \varepsilon \\ 0 & \text{otherwise} \end{cases} \quad (7)$$

or

$$S_{ij} = \begin{cases} \exp(-\|\mathbf{x}_i - \mathbf{x}_j\|^2/t), & \text{if } \mathbf{x}_i \text{ is among } k \text{ nearest neighbors of } \mathbf{x}_j \\ & \text{or } \mathbf{x}_j \text{ is among } k \text{ nearest neighbors of } \mathbf{x}_i \\ 0 & \text{otherwise,} \end{cases} \quad (8)$$

$$\begin{aligned} & \frac{1}{2} \sum_{ij} (y_i - y_j)^2 S_{ij} \\ &= \frac{1}{2} \sum_{ij} (\mathbf{w}^T \mathbf{x}_i - \mathbf{w}^T \mathbf{x}_j)^2 S_{ij} \\ &= \sum_{ij} \mathbf{w}^T \mathbf{x}_i S_{ij} \mathbf{x}_i^T \mathbf{w} - \sum_{ij} \mathbf{w}^T \mathbf{x}_i S_{ij} \mathbf{x}_j^T \mathbf{w} \\ &= \sum_i \mathbf{w}^T \mathbf{x}_i D_{ii} \mathbf{x}_i^T \mathbf{w} - \mathbf{w}^T X S X^T \mathbf{w} \\ &= \mathbf{w}^T X D X^T \mathbf{w} - \mathbf{w}^T X S X^T \mathbf{w} \\ &= \mathbf{w}^T X (D - S) X^T \mathbf{w} \\ &= \mathbf{w}^T X L X^T \mathbf{w}, \end{aligned} \quad (9)$$

در حالت کلی (با توجه به شکل ۱) الگوریتم LDA کارایی بیشتری نسبت به PCA از خود نشان می‌دهد. اما در شرایطی که مجموعه آموزش^۸ کوچک باشد الگوریتم PCA کارایی بهتری خواهد داشت. در حالت کلی نیز PCA وابستگی کمتری نسبت به LDA به مجموعه آموزش دارد.

۲- روش‌های غیر خطی

در سال‌های اخیر تحقیقاتی انجام شده است که نشان می‌دهد خصوصیات تصاویر صورت می‌توانند در ساختاری غیرخطی^۹ پنهان شده باشند. از آنجایی که هر دو الگوریتم LDA و PCA تنها توانایی درک فواصل اقلیدسی را دارند از این رو خصوصیتی از تصاویر صورت می‌تواند برای آنها پنهان بماند. راهکار حل این مشکل این است که از تکنیک‌هایی غیرخطی برای شناسایی این ساختار استفاده شود. تکنیک‌هایی نظیر Isomap، LLE، Laplacian Eigenmap همگی تکنیک‌هایی هستند که بر روی ساختارهای مصنوعی غیرخطی اطلاعات نتایج خیلی خوبی از خود نشان داده‌اند. اما با توجه به ابهاماتی که در بعضی بخش‌های آنها وجود دارد، نظیر اینکه مشخص نشده است چگونه باید پس از آموزش، از آنها برای اعمال بر روی مجموعه آزمون^{۱۰} استفاده کرد. به این دلیل احتمالاً این تکنیک‌ها برای کارهای پردازش تصویر صورت و بینایی ماشین مناسب نمی‌باشند.

۲-۱- Locality Preserving Projection (LPP)

در این مقاله روش جدیدی مبتنی بر خصوصیات محلی^{۱۱} پیشنهاد شده است که پس از کاهش ابعاد خصوصیات محلی تصاویر صورت را حفظ می‌نماید. این توجه به خصوصیات محلی که در روش‌های پیشین نادیده گرفته می‌شد موجب شده است تا این روش پیشنهادی توانایی ایجاد نتایج بهتری را نسبت به روش‌هایی نظیر

^{۱۱} Locality

^{۱۲} Kernel Function

^۸ Training dataset

^۹ Non-linear manifold

^{۱۰} Test dataset

۳- الگوریتم Laplacianfaces

این الگوریتم دارای چهار گام اصلی است:

۳-۱- کاهش ابعاد با PCA (پیش پردازش)

در این گام برای جلوگیری از مواجهه با ماتریس منفرد، از کاهش ابعاد با استفاده از PCA استفاده می‌کنیم و ماتریس این تبدیل را W_{pca} می‌نامیم.

۳-۲- ساختن گراف نزدیک نقاط همسایگی

در این مرحله گراف G که دارای n گره - که n تعداد تصاویر مجموعه آموزش است - را با این شرط می‌سازیم که در صورتی که فاصله نقطه i و j از یکدیگر باشد گره آنها را در گراف به یکدیگر متصل $S_{ij} = e^{-\frac{\|x_i - x_j\|^2}{t}}$ برت آن اتصال قطع می‌باشد. هدف اصلی این حلی اطلاعات است.

۳-۳- وزن دهی

حال باید ماتریس S را با استفاده از معادله $XLX^T \mathbf{w} = \lambda XDX^T \mathbf{w}$ نهایت ماتریس خصوصیات S ساخته شده که از آن با گام بعدی استفاده می‌شود.

$$W_{LPP} = [\mathbf{w}_0, \mathbf{w}_1, \dots, \mathbf{w}_{k-1}]$$


$$W = W_{PCA} W_{LPP}$$

۳-۴- Eigenmap

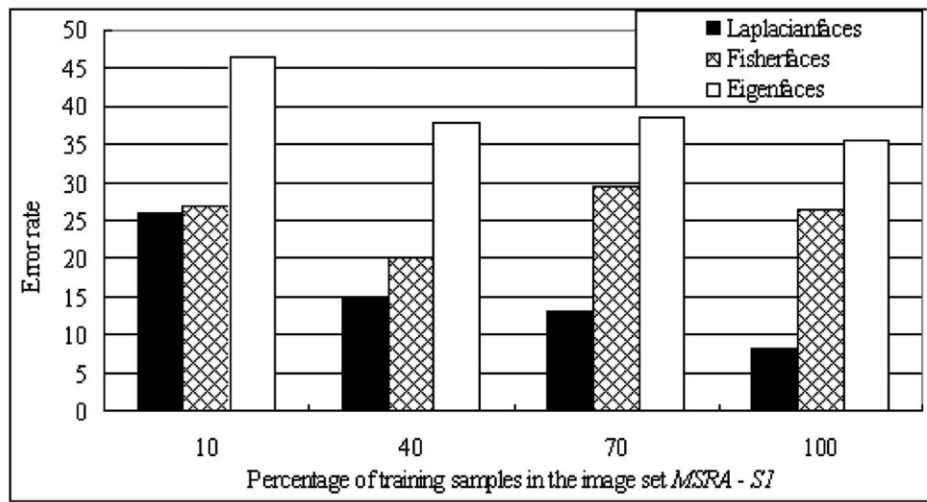
در این مرحله، مسئله اصلی تبدیل حل مسئله بردار ویژه شده که پس از حل آن ماتریس تبدیل مشخص می‌شود.

۴- فرآیند تشخیص چهره

- ۱- محاسبه ماتریس Laplacianfaces با استفاده از مجموعه آموزش
 - ۲- اعمال Laplacianfaces بر روی مجموعه تست
 - ۳- تصمیم گیری درباره تصویر صورت با استفاده از گروه بندی کننده نزدیکترین همسایگی^{۱۳}
- حال این الگوریتم را بر روی مجموعه آموزش اعمال کرده و ابعاد مجموعه تصاویر صورت ۱۰ به ۲ بعد کاهش ابعاد می‌دهیم. همانطه،



^{۱۳} Nearest-Neighbor Classifier



شکل ۳ - مقایسه سه روش مطرح شده بر اساس تعداد نمونه های آموزش و میزان خطا بر اساس پایگاه داده MSRA